Material del Curso

1. Introduccion a la Minería de Datos

Clase No 1: Introducción a la Minería de Datos y Python para Análisis de Datos

1. Presentación del Curso

¡Bienvenidos al bloque de Minería de Datos!

Mi nombre es Juan Paulo Zarza, y seré su guía a lo largo de este recorrido de 10 clases del bloque.

En esta primera clase, vamos a introducir los conceptos fundamentales, explorando cómo la minería de datos transforma grandes volúmenes de información en conocimiento útil. También nos familiarizaremos con Python y sus bibliotecas para análisis de datos. Vamos a revisar los marcos procedimentales que disponemos para ordenar nuestro trabajo

Este curso seguirá un enfoque teórico-práctico, combinando la comprensión conceptual con la aplicación real a través de código en Python.

2. Introducción a la Minería de Datos

2.1. ¿Qué es la Minería de Datos?

La Minería de Datos es una disciplina que permite descubrir patrones, tendencias y correlaciones en grandes volúmenes de datos. Se apoya en técnicas de diversas áreas como:

- Estadística: cálculo de probabilidades, distribuciones, inferencias.
- Aprendizaje Automático (Machine Learning): algoritmos supervisados y no supervisados.
- Bases de Datos: recuperación, almacenamiento y optimización de consultas.
- Inteligencia Artificial: reconocimiento de patrones, redes neuronales.

En la práctica, la minería de datos se usa para predecir tendencias, optimizar procesos y mejorar la toma de decisiones en diversos sectores.

Ejemplo Práctico

Imaginemos que una cadena de supermercados quiere mejorar su estrategia de ventas. Con minería de datos puede:

- Analizar patrones de compra para hacer ofertas personalizadas.
- Detectar productos frecuentemente comprados juntos (reglas de asociación).
- Usar clustering para segmentar clientes según su comportamiento de compra.
- Implementar modelos predictivos para anticipar la demanda de productos.

Este enfoque permite transformar datos en decisiones estratégicas, lo que da a las empresas una ventaja competitiva.

2.2. Diferencias entre Datos, Información y Conocimiento

Antes de profundizar en minería de datos, es importante entender la diferencia entre dato, información y conocimiento:

Concepto Definición Ejemplo

- ---------- ---------- ----------

Dato Unidad mínima de información, sin contexto. "25°C"

Información Dato procesado con significado. "La temperatura actual es de 25°C"

Conocimiento Interpretación de la información para la toma de decisiones. "Dado que hace calor, la venta de bebidas frías aumentará"

Ejemplo en un contexto empresarial

Un negocio de ventas en línea recopila miles de registros diarios.

- Dato: "500 visitas a la tienda online".
- Información: "500 visitas diarias, de las cuales el 10% finalizan en compras".
- Conocimiento: "Optimizar la página de pagos podría aumentar la conversión en un 5%".

La minería de datos actúa transformando datos en conocimiento útil.

2.3. Aplicaciones de la Minería de Datos

La minería de datos se aplica en una amplia variedad de sectores.

Principales aplicaciones:

1. Detección de fraudes (Banca y Finanzas)

Los bancos utilizan minería de datos para identificar transacciones sospechosas.

Ejemplo:

Si un cliente que normalmente hace compras en Argentina realiza una compra de alto valor en otro país, el sistema puede detectar una anomalía y bloquear la transacción.

2. Recomendaciones de productos (Retail y e-commerce)

Amazon, MercadoLibre y otras plataformas analizan el comportamiento de los usuarios para ofrecer recomendaciones personalizadas.

Ejemplo:

Si compras una laptop, el sistema te sugiere un mouse y una funda, porque otros clientes con hábitos similares hicieron compras relacionadas.

3. Minería de datos en Salud

Se usa para predecir enfermedades y personalizar tratamientos.

Ejemplo:

Un hospital puede analizar datos de miles de pacientes para predecir riesgos de enfermedades cardíacas en función de la edad, peso y antecedentes familiares.

4. Marketing y segmentación de clientes

Las empresas analizan datos de consumo para segmentar clientes en grupos homogéneos y dirigir campañas personalizadas.

Ejemplo:

Netflix analiza qué tipos de series ves y por cuánto tiempo, para recomendarte contenidos basados en tu comportamiento y en el de otros usuarios similares.

5. Minería de datos en transporte y logística

Las empresas optimizan rutas de entrega para reducir costos.

Ejemplo:

Uber usa minería de datos para predecir la demanda y ajustar sus precios en función del tráfico y la cantidad de conductores disponibles.

2.4. ¿Cómo se relaciona la minería de datos con el Machine Learning?

Muchas veces, Minería de Datos y Machine Learning son términos que se confunden.

- Minería de Datos → Descubre patrones en datos históricos.
- Machine Learning → Usa patrones descubiertos para hacer predicciones automáticas en nuevos datos.

-

Ejemplo práctico:

- Minería de datos: Un supermercado descubre que los clientes que compran leche también suelen comprar pan.
- Machine Learning: Se entrena un modelo para predecir qué productos comprará un cliente, basado en su historial de compras

.[]

Minería de Datos extrae patrones. Machine Learning usa esos patrones para predecir.

Punto clave de esta sección:

La minería de datos no solo analiza datos históricos, sino que también ayuda a predecir eventos futuros y a optimizar la toma de decisiones en distintos sectores.

Ejercicio para la Sección 2: Introducción a la Minería de Datos

Objetivo: Comprender la diferencia entre dato, información y conocimiento, y explorar cómo la minería de datos puede descubrir patrones en un conjunto de datos.

Ejercicio 1: Identificación de Datos, Información y Conocimiento

A continuación, se presentan tres situaciones. Para cada una, identifica qué es el dato, la información y el conocimiento.

1. Un banco analiza 10,000 transacciones realizadas en las últimas 24 horas. Encuentra que 2,000 transacciones provienen de cuentas recién creadas y de países donde no opera habitualmente. Basándose en esto, activa un sistema de alerta para detectar fraudes.

2. Una tienda online nota que el 70% de los clientes que compran laptops también compran fundas protectoras en un lapso de 7 días. Basado en este hallazgo, comienza a ofrecer un descuento del 10% en fundas al comprar una laptop.

3. Un hospital analiza los registros médicos de 50,000 pacientes y descubre que las personas con hipertensión tienen un 40% más de probabilidades de desarrollar enfermedades cardíacas en los próximos 10 años. Con base en esto, implementa un programa preventivo de chequeos cardíacos gratuitos para personas con hipertensión.

Instrucciones:

- Para cada caso, señala cuál es el dato, cuál la información y cuál el conocimiento.
- Explica en pocas palabras cómo la minería de datos ayuda en cada situación.

Ejemplo de respuesta (para el primer caso):

- Dato: "10,000 transacciones en 24 horas".
- Información: "2,000 transacciones provienen de cuentas nuevas y de países inusuales".
- Conocimiento: "Si una transacción proviene de una cuenta nueva y de un país inusual, es más probable que sea fraudulenta".
- Papel de la Minería de Datos: Detectó un patrón que permite mejorar la seguridad del banco.

Sección 3: Proceso KDD y CRISP-DM

3. Proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD)

El Proceso KDD (Knowledge Discovery in Databases) es una metodología ampliamente utilizada para extraer conocimiento a partir de grandes volúmenes de datos.

Se compone de cinco fases fundamentales:

1. Selección de datos
   - Se eligen los datos relevantes para el problema a analizar.
   - Ejemplo: Un e-commerce selecciona datos de compras de los últimos 2 años para analizar patrones de compra.
2. Preprocesamiento y limpieza de datos
   - Se eliminan valores erróneos, duplicados o inconsistentes.
   - Ejemplo: Un hospital elimina registros con edades negativas o fechas imposibles.
3. Transformación de datos
   - Se convierten los datos en un formato adecuado para el análisis.
   - Ejemplo: Convertir datos de texto en valores numéricos para análisis en Machine Learning.
4. Minería de datos
   - Se aplican algoritmos para encontrar patrones o tendencias.
   - Ejemplo: Identificar clientes con alto riesgo de abandonar un servicio mediante análisis de comportamiento.
5. Evaluación e interpretación
   - Se analizan los patrones obtenidos para validar su utilidad.
   - Ejemplo: Un banco revisa si los patrones descubiertos ayudan a detectar fraudes.

Ejemplo en Python – Inspección de Datos en Pandas

```
import pandas as pd

# Cargar datos desde un archivo CSV
df = pd.read_csv("ventas.csv")
# Mostrar primeras filas

print(df.head())

# Verificar si hay valores faltantes

print(df.isnull().sum())

# Resumen estadístico de los datos numéricos

print(df.describe())
```

Este código muestra cómo seleccionar, limpiar y explorar datos, cubriendo las primeras fases del proceso KDD.

3.1. CRISP-DM: Modelo Estándar para la Minería de Datos

Además del proceso KDD, otro modelo ampliamente utilizado en la industria es CRISP-DM (Cross Industry Standard Process for Data Mining).

Fases de CRISP-DM:

1. Comprensión del negocio: Se definen objetivos y necesidades del proyecto.
2. Comprensión de los datos: Se analizan fuentes de datos y calidad de la información.
3. Preparación de los datos: Se limpian y transforman datos para análisis.
4. Modelado: Se aplican algoritmos de minería de datos (clustering, regresión, árboles de decisión, etc.).
5. Evaluación: Se valida la calidad y utilidad de los modelos generados.
6. Despliegue: Se implementan los modelos en producción para uso real.

Ejemplo de Aplicación de CRISP-DM:

Una empresa de telecomunicaciones quiere predecir qué clientes van a cancelar su servicio.

- Comprensión del negocio: Entender las razones por las que los clientes abandonan.
- Comprensión de los datos: Analizar datos de facturación, llamadas al soporte y encuestas.
- Preparación de los datos: Eliminar clientes duplicados y corregir valores inconsistentes.
- Modelado: Aplicar Machine Learning para predecir clientes propensos a cancelar.

- Evaluación: Medir precisión del modelo y ajustarlo según resultados.
- Despliegue: Implementar un sistema de alertas para retener clientes en riesgo.

Comparación entre KDD y CRISP-DM

Característica KDD CRISP-DM

- --- --- ---

Enfoque Más académico Más empresarial

Fases 5 fases 6 fases

Objetivo Descubrimiento de patrones Aplicación práctica en negocios

Nivel de detalle Menos estructurado Más detallado en cada fase

Ejercicio para la Sección 3.

Objetivo: Aplicar los conceptos del proceso KDD y CRISP-DM en situaciones reales y con datos sencillos.

Ejercicio 1: Identificación de Fases del Proceso KDD

A continuación, se presentan cuatro situaciones. Para cada una, identifica a qué fase del proceso KDD pertenece.

1. Un equipo de científicos de datos descarga una base de datos con información sobre ventas en un supermercado.
2. Se eliminan registros con datos faltantes y se corrigen inconsistencias en los formatos de fechas.
3. Se aplica un algoritmo de agrupamiento (clustering) para segmentar clientes según su comportamiento de compra.
4. Se presentan los resultados en un informe y se analizan los patrones descubiertos.

Instrucciones:

- Asocia cada situación con una fase del proceso KDD: Selección, Preprocesamiento, Transformación, Minería de Datos o Evaluación.

Ejercicio 2: Aplicación del Modelo CRISP-DM

Un banco quiere detectar fraudes en transacciones. Relaciona cada acción con la fase de CRISP-DM correspondiente:

1. Se analizan casos anteriores de fraude y se definen los objetivos del análisis.
2. Se limpian y transforman los datos de transacciones.
3. Se prueban diferentes modelos de Machine Learning para encontrar patrones de fraude.
4. Se analiza la efectividad de los modelos y se elige el más preciso.
5. Se implementa un sistema automático que detecta fraudes en tiempo real.

Instrucciones:

- Indica a qué fase de CRISP-DM pertenece cada acción: Comprensión del Negocio, Comprensión de los Datos, Preparación de Datos, Modelado, Evaluación o Despliegue.

Sección 4: Preprocesamiento y Análisis Exploratorio de Datos

El preprocesamiento de datos es una etapa clave en minería de datos, ya que los datos en bruto suelen contener errores, valores atípicos o datos faltantes.

4.1. Limpieza de Datos

Los datos pueden contener problemas como:

- Valores nulos o faltantes → Registros sin información en algunas columnas.
- Valores duplicados → Registros repetidos que generan sesgo en el análisis.
- Valores inconsistentes → Datos incorrectos o fuera de rango (ej: edades negativas).

Ejemplo en Python – Identificación de Problemas

```
import pandas as pd

# Cargar datos ficticios

datos = {

"Nombre": ["Ana", "Luis", "Carlos", None, "Marta"],
"Edad": [25, None, 40, 35, -5],
"Salario": [50000, 55000, 60000, 58000, None]
}
df = pd.DataFrame(datos)
# Ver valores faltantes

print(df.isnull().sum())
```

```
# Ver datos fuera de rango

print(df[df["Edad"] < 0])
```

Acciones recomendadas:

- Eliminar filas con demasiados valores faltantes.
- Imputar valores faltantes con la media o la mediana.
- Corregir valores atípicos detectados.

4.2. Transformación de Datos

Después de limpiar los datos, se pueden realizar transformaciones para facilitar el análisis.

Tareas comunes:

- Normalización: Escalar valores numéricos entre 0 y 1.
- Codificación de variables categóricas: Convertir texto en valores numéricos para modelos de Machine Learning.
- Creación de nuevas variables: Extraer información relevante de datos existentes.

Ejemplo en Python – Normalización y Codificación

```
from sklearn.preprocessing import MinMaxScaler, LabelEncoder

# Normalización de la columna "Salario"
```

scaler = MinMaxScaler()

df["Salario_Normalizado"] = scaler.fit_transform(df[["Salario"]])

```
# Codificación de la columna "Nombre"
```

encoder = LabelEncoder()

df["Nombre_Codificado"] = encoder.fit_transform(df["Nombre"].astype(str)) print(df)

4.3. Análisis Exploratorio de Datos (EDA)

Antes de aplicar modelos de minería de datos, es fundamental explorar los datos con visualizaciones y estadísticas descriptivas.

Herramientas clave:

- Histogramas → Para ver la distribución de una variable.
- Boxplots → Para detectar valores atípicos.
- Mapas de calor → Para analizar correlaciones entre variables.

Ejemplo en Python – Visualización de Datos

```
import seaborn as sns

import matplotlib.pyplot as plt

# Histograma de edades

sns.histplot(df["Edad"].dropna(), bins=5, kde=True)

plt.show()

# Boxplot de salarios

sns.boxplot(x=df["Salario"])

plt.show()
```

Interpretación de Resultados:

- Un histograma ayuda a identificar sesgos en la distribución.
- Un boxplot permite ver si hay valores atípicos.

Ejercicios para la Sección 4

Ejercicio 1: Detección de Problemas en Datos

Supón que tienes el siguiente conjunto de datos de estudiantes:

Nombre Edad Nota

- ---- ------ ------

Juan 22 8

Sofía -3 10

Lucas 25 6

Ana 20 None

Marcos 21 4

Instrucciones:

1. **Identifica los problemas en estos datos.**
2. **¿Cómo los corregirías? (eliminar, reemplazar, corregir valores negativos, etc.).**
3. **¿Qué tipo de transformación aplicarías antes de analizar los datos?**

Ejercicio 2: Creación de Gráficos en Python

Crea un DataFrame con los siguientes datos de ventas:

Producto Precio Cantidad_Vendida

- ------ -------- ----------

A 10 50

B 20 30

C 15 40

D 25 20

Instrucciones:

1. **Escribe código en Python para crear un histograma de precios.**
2. **Crea un gráfico de dispersión de Precio vs Cantidad_Vendida.**
3. **Interpreta los resultados de los gráficos.**

Ejercicio Integrador – Clase 1: Introducción a la Minería de Datos

Objetivo: Aplicar los conceptos aprendidos sobre Minería de Datos, KDD, CRISP-DM, Preprocesamiento y Exploración de Datos en un ejercicio práctico.

Contexto del Problema

Una empresa de telecomunicaciones quiere analizar los datos de sus clientes para identificar patrones de consumo y detectar posibles cancelaciones de servicio. Se tiene un conjunto de datos con la siguiente información:

Cliente Edad Plan Contratado Consumo de Datos (GB) Reclamos en el Último Año Estado de Cuenta (Pagado/Moroso)

- ----- ------ ---------- ---------- ---------- ----------

1 25 Básico 5 1 Pagado

2 40 Premium 50 0 Pagado

3 32 Estándar 10 2 Moroso

4 22 Básico 7 3 Moroso

5 35 Premium 45 0 Pagado

Tareas a Realizar

1. Identificación de Fases en KDD y CRISP-DM

- ¿Cómo aplicaría el proceso KDD a estos datos?
- ¿Qué pasos seguirías antes de extraer patrones?
- ¿Qué fase de CRISP-DM corresponde a cada acción en este análisis?

2. Preprocesamiento de Datos

- ¿Qué problemas podrías encontrar en los datos?
- ¿Hay valores inconsistentes o que deban transformarse?
- ¿Cómo manejarías los valores categóricos (Plan Contratado, Estado de Cuenta)?
- Escribe el código en Python para cargar los datos en un DataFrame de Pandas y verificar valores faltantes o duplicados.

3. Exploración de Datos

- Genera un histograma del consumo de datos (GB) para analizar la distribución.
- Crea un gráfico de barras del "Estado de Cuenta" para ver cuántos clientes son morosos.

4. Interpretación de Resultados

- ¿Qué tendencias observas en los datos?
- ¿Hay alguna relación entre el consumo de datos y el estado de cuenta?
- ¿Los clientes morosos tienen características en común?

Código Base para Resolver el Ejercicio

Aquí tienes un punto de partida para analizar los datos en Python:

```
import pandas as pd

import seaborn as sns

import matplotlib.pyplot as plt

# Crear DataFrame con los datos del ejercicio

datos = {
"Cliente": [1, 2, 3, 4, 5],
"Edad": [25, 40, 32, 22, 35],
"Plan": ["Básico", "Premium", "Estándar", "Básico", "Premium"],
"Consumo_GB": [5, 50, 10, 7, 45],
"Reclamos": [1, 0, 2, 3, 0],
"Estado_Cuenta": ["Pagado", "Pagado", "Moroso", "Moroso", "Pagado"]
}
df = pd.DataFrame(datos)
# Inspeccionar los datos

print(df.info())

print(df.describe())

# Ver distribución de consumo de datos

sns.histplot(df["Consumo_GB"], bins=5, kde=True)

plt.show()

# Gráfico de barras de Estado de Cuenta

sns.countplot(x=df["Estado_Cuenta"])

plt.show()
```

Publicación en el Foro

1. **Comparte tu análisis en el foro de la clase con:**
   - Breve resumen de tu interpretación de los datos.
   - Explicación de qué fase del KDD y CRISP-DM consideraste más relevante.
   - Capturas o gráficos de los resultados obtenidos.
2. **Comenta y participa en la publicación de otro compañero:**
   - Ofrece una observación o mejora sobre su análisis.
   - Discute si hay otras interpretaciones posibles.
   - Si encontraste un patrón diferente, compáralo con el de tu compañero.

Objetivo de la participación: Aprender desde distintas perspectivas y consolidar el conocimiento aplicando minería de datos en la práctica.

Bibliografía

1. **Han, J., Kamber, M., & Pei, J. (2012). Data Mining: Concepts and Techniques (3rd ed.). Elsevier. ISBN: 978-0-12-381479-1.**
2. **Hernández Orallo, J., Ramírez Quintana, M. J., & Ferri Ramírez, C. (2004). Introducción a la Minería de Datos. Pearson-Prentice Hall.**
3. **Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2017). Data Mining: Practical Machine Learning Tools and Techniques. Morgan Kaufmann Publishers.**
4. **Layton, R. (2017). Learning Data Mining with Python (2nd ed.). Packt Publishing.**
5. **Python Software Foundation. (n.d.). Welcome to Python.org. Recuperado el [fecha de consulta], de https://www.python.org/**

6. **The pandas development team. (n.d.). Pandas: Powerful Python Data Analysis Toolkit. Recuperado el [fecha de consulta], de https://pandas.pydata.org/**

7. **Project Jupyter. (n.d.). Project Jupyter. Recuperado el [fecha de consulta], de https://jupyter.org/**