1. `Identificación de Tipos de Datos`

Clasifica cada columna según su tipo (numérico, categórico, ordinal, fecha) y explica cómo se debería manejar cada una.

ID: numérico (identificador)

Nombre: categórico (texto)

Edad: numérico (valores negativos en fila 1)

Nivel Educativo: categórico ordinal (Licenciado - Ingeniero - Doctorado)

Salario: numérico: (faltantes y outliers)

Categoría: categórico(Junior, Senior, Manager)

Estado: categórico (Activo-1 / Inactivo-0, con inconsistencias)

```
import pandas as pd

# Dataset
df = pd.DataFrame({
    "ID": [1, 2, 3, 4, 5],
    "Nombre": ["Juan", "Maria", "Pedro", "Ana", "Luis"],
    "Edad": [32, -28, 40, 35, 50],
    "Nivel_Educativo": ["Licenciado", "Ingeniero", "Doctorado", "Licenciado", "Doctorado"],
    "Salario": [50000, 60000, None, 55000, 200000],
    "Categoria": ["Junior", "Senior", "Senior", "Junior", "Manager"],
    "Estado": ["Activo", "ACTIVO", "Inactivo", "Activo", "Inactivo"]
})

# Ver tipos de datos
print(df.head)
print(df.dtypes)
```

```
<bound method NDFrame.head of    ID Nombre  Edad Nivel_Educativo   Salario Categoria    Estado
0   1   Juan    32      Licenciado   50000.0    Junior    Activo
1   2  Maria   -28       Ingeniero   60000.0    Senior    ACTIVO
2   3  Pedro    40       Doctorado       NaN    Senior  Inactivo
3   4    Ana    35      Licenciado   55000.0    Junior    Activo
4   5   Luis    50       Doctorado  200000.0   Manager  Inactivo>
ID                  int64
Nombre             object
Edad                int64
Nivel_Educativo    object
Salario           float64
Categoria          object
Estado             object
dtype: object
```

2. `Limpieza de Datos`

• Detecta y corrige valores faltantes en las columnas necesarias.

• Identifica y elimina valores atípicos en la columna “Salario”.

• Corrige inconsistencias en los datos categóricos (ejemplo: "Licenciado" y "licenciado" deben ser tratados como el mismo valor).

```
import pandas as pd
from sklearn.preprocessing import MinMaxScaler, OrdinalEncoder

# Cargar los datos
df = pd.DataFrame({
"ID": [1, 2, 3, 4, 5],
"Nombre": ["Juan", "María", "Pedro", "Ana", "Luis"],
"Edad": [32, -28, 40, 35, 50],
"Nivel_Educativo": ["Licenciado", "Ingeniero", "Doctorado", "Licenciado", "Doctorado"],
"Salario": [50000, 60000, None, 55000, 200000],
"Categoria": ["Junior", "Senior", "Senior", "Junior", "Manager"],

"Estado": ["Activo", "ACTIVO", "Inactivo", "Activo", "Inactivo"]
})

# 1 Corrección de edad negativa
df["Edad"] = df["Edad"].abs()
# 2 Imputación del salario faltante con la mediana
#df["Salario"].fillna(df["Salario"].median(), inplace=True)
df["Salario"] = df["Salario"].fillna(df["Salario"].median())

# 3 Detectar y eliminar valores atípicos con IQR
Q1, Q3 = df["Salario"].quantile([0.25, 0.75])
```

```
IQR = Q3 - Q1
df = df[(df["Salario"] > (Q1 - 1.5 * IQR)) & (df["Salario"] < (Q3 + 1.5 * IQR))]
# 4 Unificar formato de columna Estado
df["Estado"] = df["Estado"].str.lower()
# Nuevo indece ID
df.set_index("ID", inplace=True)
df.index.name = None
print(df)
```

```
  Nombre  Edad Nivel_Educativo  Salario Categoria    Estado
1   Juan    32      Licenciado  50000.0    Junior    activo
2  María    28       Ingeniero  60000.0    Senior    activo
3  Pedro    40       Doctorado  57500.0    Senior  inactivo
4    Ana    35      Licenciado  55000.0    Junior    activo
```

3. `Transformación de Datos`

- Convierte las variables categóricas en numéricas utilizando codificación ordinal o One-Hot Encoding.
- Aplica normalización al salario para facilitar comparaciones.
- Crea una nueva variable "Años hasta jubilación" suponiendo que la edad de retiro es 65 años.

```
import pandas as pd
from sklearn.preprocessing import MinMaxScaler, OrdinalEncoder, LabelEncoder

# Cargar los datos
df = pd.DataFrame({
"ID": [1, 2, 3, 4, 5],
"Nombre": ["Juan", "María", "Pedro", "Ana", "Luis"],
"Edad": [32, -28, 40, 35, 50],
"Nivel_Educativo": ["Licenciado", "Ingeniero", "Doctorado", "Licenciado", "Doctorado"],
"Salario": [50000, 60000, None, 55000, 200000],
"Categoria": ["Junior", "Senior", "Senior", "Junior", "Manager"],

"Estado": ["Activo", "ACTIVO", "Inactivo", "Activo", "Inactivo"]
})

# 1 Corrección de edad negativa
df["Edad"] = df["Edad"].abs()
# 2 Imputación del salario faltante con la mediana
#df["Salario"].fillna(df["Salario"].median(), inplace=True)
df["Salario"] = df["Salario"].fillna(df["Salario"].median())

# 3 Detectar y eliminar valores atípicos con IQR
Q1, Q3 = df["Salario"].quantile([0.25, 0.75])
IQR = Q3 - Q1
df = df[(df["Salario"] > (Q1 - 1.5 * IQR)) & (df["Salario"] < (Q3 + 1.5 * IQR))]
# 4 Unificar formato de columna Estado
df["Estado"] = df["Estado"].str.lower()
# Nuevo indece ID
df.set_index("ID", inplace=True)
df.index.name = None
# 5 Codificación ordinal para "Nivel Educativo"
encoder_ordinal = OrdinalEncoder(categories=[["Licenciado", "Ingeniero", "Doctorado"]])
df["Nivel_Cod"] = encoder_ordinal.fit_transform(df[["Nivel_Educativo"]])

# 6 Normalización del salario
scaler = MinMaxScaler()
df["Salario_Normalizado"] = scaler.fit_transform(df[["Salario"]])

# 7 Creación de nueva variable "Años hasta jubilación"
df["Años_Hasta_Jubilación"] = 65 - df["Edad"]
#8
from sklearn.preprocessing import LabelEncoder

encoder = LabelEncoder()
df["Estado_cod"] = encoder.fit_transform(df["Estado"])

# Invertir valores
df["Estado_cod"] = df["Estado_cod"].map({0: 1, 1: 0})

print(df)
```

```
  Nombre  Edad Nivel_Educativo  Salario Categoria    Estado  Nivel_Cod  \
1   Juan    32      Licenciado  50000.0    Junior    activo        0.0
2  María    28       Ingeniero  60000.0    Senior    activo        1.0
3  Pedro    40       Doctorado  57500.0    Senior  inactivo        2.0
4    Ana    35      Licenciado  55000.0    Junior    activo        0.0

   Salario_Normalizado  Años_Hasta_Jubilación  Estado_cod
```

```
1                0.00                    33          1
2                1.00                    37          1
3                0.75                    25          0
4                0.50                    30          1
```

```
import matplotlib.pyplot as plt
import seaborn as sns

sns.histplot(df["Salario"], kde=True)
plt.title("Distribución de Salarios")
plt.show()
```

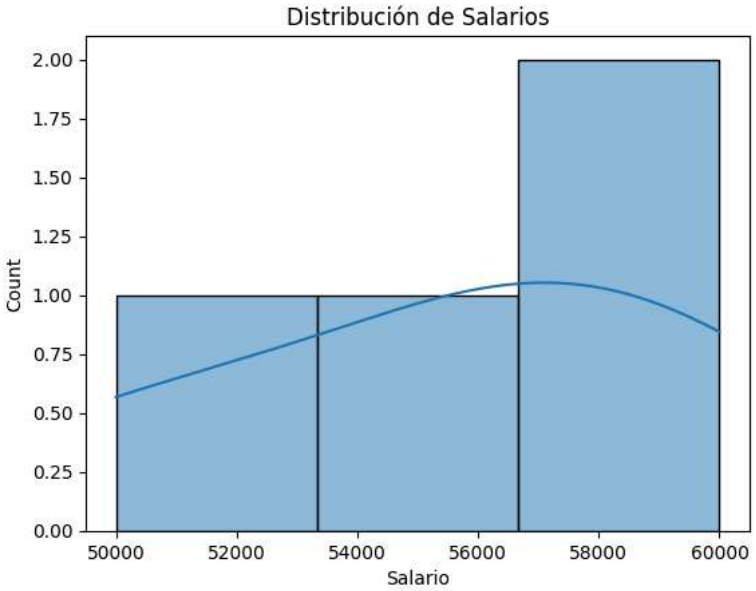

Visualización 1: Distribución de Salarios

En el histograma se observa que los salarios se distribuyen entre 50.000 y 60.000, con una mayor concentración en los valores más altos del rango (alrededor de 55.000–60.000).

No se observan valores extremos, lo que indica que el proceso de eliminación de outliers fue adecuado. Además, la distribución no es completamente uniforme debido a la poca cantidad de datos, pero permite identificar un rango salarial relativamente homogéneo dentro de la empresa.

```
sns.scatterplot(x="Edad", y="Salario", data=df)
plt.title("Relación Edad vs Salario")
plt.show()
```

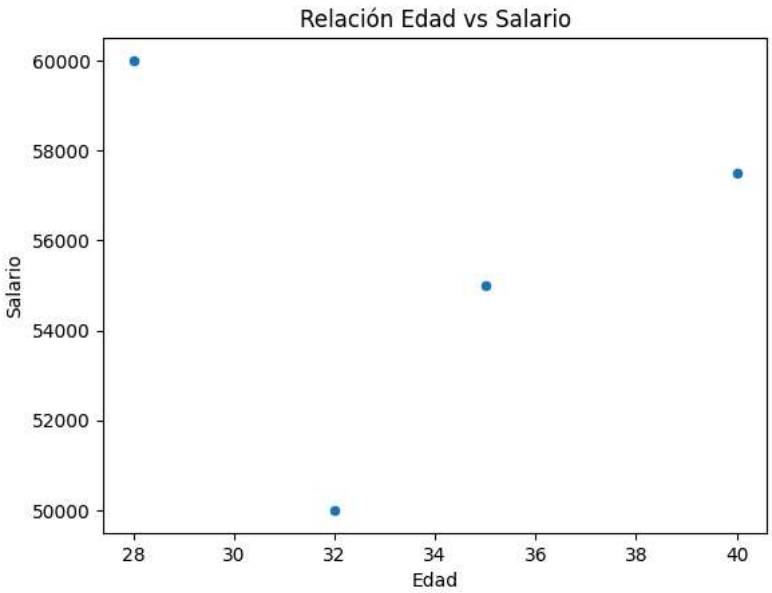

Visualización 2: Relación Edad vs Salario

El gráfico de dispersión muestra que no existe una relación lineal clara entre la edad y el salario.

Esto indica que el salario no depende únicamente de la edad, sino que probablemente está influenciado por otros factores como el nivel educativo o la categoría laboral.

Conclusión del EDA

El análisis exploratorio muestra que los salarios se concentran en un rango medio y relativamente homogéneo.

Además, no se evidencia una relación directa entre edad y salario, lo que sugiere que existen otras variables relevantes en la determinación de los ingresos.

Prompt 1

Consulta: "¿Qué gráficos son más adecuados para analizar la relación entre edad, salario y nivel educativo?"

Síntesis:

El LLM sugirió usar histogramas para distribución, scatter plots para relaciones entre variables numéricas y boxplots para comparar salarios según categorías. También recomendó usar colores para diferenciar niveles educativos.

Validación propia:

Estos gráficos permiten visualizar tanto distribución como relaciones entre variables, facilitando la interpretación.

Prompt 2

Consulta: "¿Qué errores comunes se cometen en el preprocesamiento de datos?"

Síntesis:

El LLM mencionó errores como no tratar valores faltantes, ignorar outliers y no escalar variables numéricas.

Validación propia:

Coincide con el proceso realizado, donde se abordaron estos problemas en etapas de limpieza y transformación.